vLLM-HUST 介绍

面向国产算力与 AGI4S 场景的可演进推理底座

HUST 团队

二〇二六年五月

汇报提纲

1. 定位与背景
2. 系列仓库
3. 技术架构
4. 工程交付
5. 进展与路线

项目定位

vLLM-HUST 是什么

vLLM-HUST 以 upstream vLLM 为基础，围绕国产算力适配、AGI4S 服务场景与benchmark驱动验证建设可持续演进的推理系统底座。

目标

- 保持与 upstream 的持续合并能力
- 支撑国产硬件上的高吞吐、低时延、低成本服务
- 为多模态、智能体、工具调用和长上下文提供统一底座

方法

- 插件优先，缩小 fork 差异面
- 平台隔离，避免共享热路径散落硬件分支
- 用真实 workload 评估，而非只看微基准

为什么需要 vLLM-HUST

场景牵引

- 国产硬件环境下，推理执行图、通信运行时与多级存储协同优化难度高
- AGI4S、多模态智能体、行业级 RAG 要求同时满足长上下文、工具调用和流式交互
- 真实交付还需要部署、修复、指标、展示和回归闭环

核心矛盾

- 软硬协同难
- KV 状态难管理
- 异构互联难提效
- 性能收益难被稳定证明

建设重点：在保持主干可持续演进的前提下，将国产算力需求与复杂场景需求落实到可维护、可验证的扩展边界。

系列仓库版图

仓库	职责
vllm-hust	主推理运行时，围绕 upstream vLLM 做可持续合并的增强
vllm-ascend-hust	Ascend 平台插件与 NPU 侧实现，隔离硬件特化逻辑
ascend-runtime-manager	Ascend 运行时诊断、环境修复、容器化与一键启动入口
vllm-hust-workstation	本地工作站，聚合聊天、监控、外部应用接入与演示栈管理
vllm-hust-website	官网、版本元数据、workstation 嵌入与 leaderboard 展示
vllm-hust-benchmark	benchmark wrapper、结果导出与 website 聚合入口
vllm-hust-docs	架构拆解、运维指南、同步记录与对外介绍材料
EvoScientist	外部多智能体真实业务负载，用于验证 agent 场景承载能力

端到端协同链

入口层

- OpenAI-compatible API
- workstation Web 交互界面
- 外部多智能体 workload 接入
- website 与 docs 展示入口

平台与治理层

- platform interface + plugin discovery
- Ascend plugin 独立演进
- runtime manager 负责环境修复与容器工作流

运行时层

- CLI / API / offline 推理入口
- V1 engine、EngineCore、executor、worker
- model registry、loader、KV cache、quantization、compilation

验证与发布层

- benchmark wrapper 统一实验入口
- artifact 聚合到 website leaderboard
- docs 持续沉淀架构与运维知识

vLLM-HUST 核心架构分层

分层	主要内容
接口与入口层	CLI、OpenAI 兼容服务、离线推理入口
参数与配置层	EngineArgs、VllmConfig，以及 model/cache/parallel/multimodal 等 schema
请求编排层	renderer、input processor、output processor、流式生命周期管理
引擎核心层	V1 LLMEngine、EngineCore、调度、连续批处理与 core 通信
模型执行层	model registry、model loader、worker、runner、layers、kernels
平台与插件层	platform interface、builtin detectors、platform plugins、general plugins
横切能力层	multimodal、reasoning、tool parser、structured outputs、renderers
性能基础设施层	KV cache、quantization、compilation、distributed、profiling、tracing

设计原则

面向国产硬件和复杂场景的差异化需求，通过分层抽象、平台接口与插件机制分别归入合适的实现边界。

vLLM-HUST 的推理执行全景

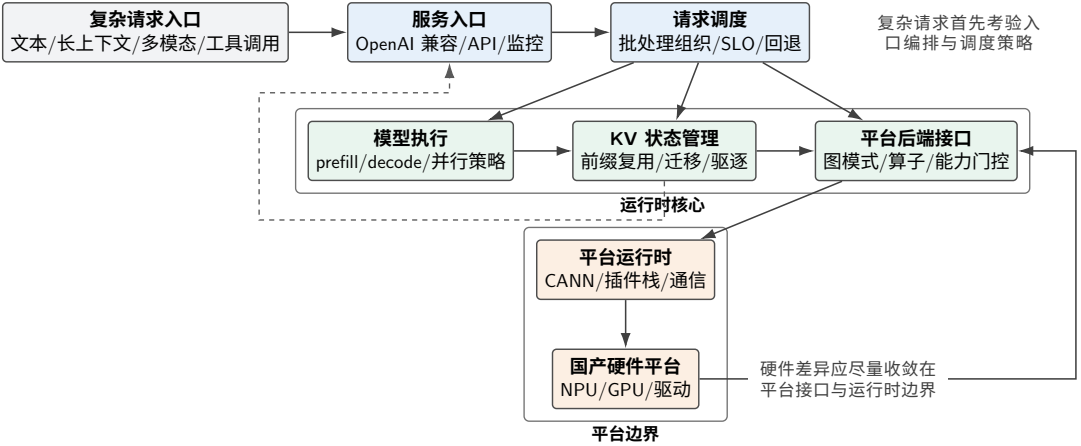

总图对应到 vLLM-HUST 的三层实现边界

服务入口与调度层

OpenAI 兼容入口、workstation 接入、请求编排、连续批处理和流式生命周期管理，决定请求如何进入系统并被组织执行。

执行与后端边界

model registry、loader、worker、runner、KV cache、quantization、compilation 与 platform interface 共同决定请求如何被真正执行，以及不同后端能力如何被接入。

平台与治理层

runtime manager、CANN/torch_npu、容器工作流和 benchmark 回归链路负责把硬件差异、环境修复和交付验证限制在可维护边界内。

国产硬件适配路径：保持主干可合并性

主仓库负责的边界

- env override：import 前最小环境补齐
- CLI 预检：尽早发现 torch_npu / runtime 问题
- platform interface：平台能力抽象与后端选择
- plugin discovery：外部硬件实现的标准挂载点

当前重点平台与扩展方向

- 当前主要适配：华为昇腾、沐曦、海光、百度昆仑芯
- 当前重点放在华为昇腾，但架构不绑定单一硬件路线
- 平台插件、runtime manager、benchmark 共同支撑后续平台扩展

效果：主干差异范围更可控，硬件特化逻辑可独立演进、独立验证和独立回归。

vLLM-HUST 的演进主线

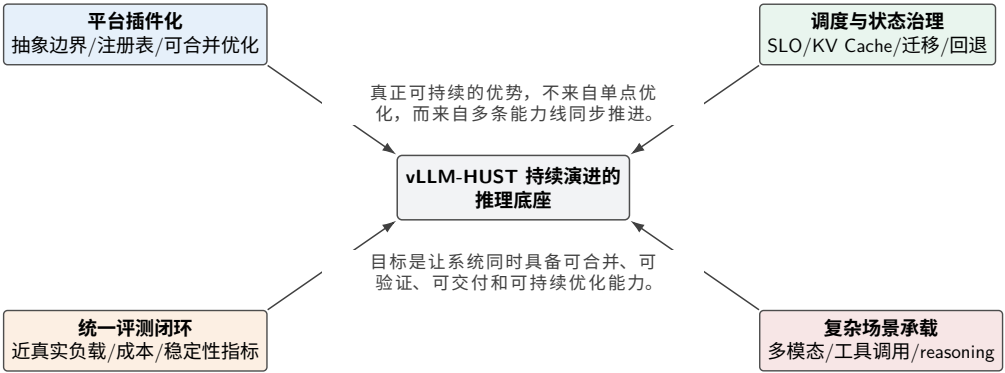

当前建设重点

后端插件化

用 vllm-hust 与 vllm-ascend-hust 的分层保持 merge-safe，尽量不把硬件特化逻辑散落到共享热路径。

资源管理与调度

围绕 SLO、KV cache、迁移、回退与阶段解耦，解决真实业务负载下的吞吐与稳定性问题。

统一评测与观测

通过 benchmark、website、docs 和 artifact 元数据形成持续回归与对外展示闭环。

模型结构演进

让底座持续承接多模态、工具调用、reasoning 和语音交互等复杂请求形态。

AGI4S 能力链：输入、执行、输出一体化

输入侧

- chat template / renderer
- multimodal registry
- 多模态预算与预处理

执行侧

- continuous batching
- 长上下文与 KV cache 管理
- streaming 与 structured outputs

输出侧

- reasoning parser
- tool parser
- OpenAI 兼容响应装配

- 当前结构已将多模态、reasoning、tool calling 纳入核心能力体系。
- 因而 vLLM-HUST 能够支撑多智能体、科研自动化和复杂交互 workload。

工程化交付链路

对外入口

- workstation 负责本地交互、监控面板、外部应用接入和演示控制
- website 负责项目展示、版本元数据、workstation 嵌入和 benchmark 榜单

实验与回归

- benchmark wrapper 提供统一实验入口，结果导出为 leaderboard artifact 与 manifest
- website 聚合结果，docs 负责架构、操作和长期介绍材料沉淀

运行时治理

- runtime repair、container、ssh-deploy 提供标准化运行时治理入口
- 把环境修复、诊断和容器化从模型执行热路径中拆开管理

一句话概括

vLLM-HUST 不只是推理内核，还把运行、验证、展示和知识沉淀串成一条完整交付链路。

workstation 工作台实景

用于演示控制、状态观察、外部应用接入和本地交互。

当前阶段判断

已经基本明确的部分

- 底层路线已经清晰：以 merge-safe 的平台分层承接国产硬件差异，以统一推理底座承接复杂场景需求。
- 关键能力已经成形：多模态、流式输出、reasoning、tool calling 和 structured outputs 已具备服务化承载基础。
- 工程闭环已经打通：运行、验证、展示和文档沉淀不再割裂，能够支撑持续演进与对外说明。

当前仍需重点补强的部分

- 更接近真实业务的多智能体与长链路 workload 验证。
- 跨硬件、跨配置、跨阶段的一致性回归与稳定性证明。

验证与度量闭环

关键指标

- TTFT、ITL、TPOT、吞吐、token 速率
- 长上下文稳定性、多租户利用率、工具调用链路质量

实验入口与产物

- vllm bench serve / throughput / latency
- wrapper 仓库统一提供 run / run-both / export / publish 入口
- benchmark 结果导出为 leaderboard artifact 与 manifest

展示与回归

- website 聚合结果并持续展示横向对比
- docs 解释指标口径、测试入口和阶段结论
- 统一度量体系为国产硬件适配与 AGI4S 优化提供共同证据

benchmark 榜单快照

VLLM BENCHMARK

性能排行榜 • sharegpt-online 版本对比

Qwen2.5-7B-Instruct / 1 x 910B3 / sharegpt-online 的公开版本记录。

当前可用的同 workload 公开提交共有 2 条，commit 在官网列表中可直接点击跳转。

引擎 / 版本	工作负载	硬件	TTFT (ms) ↓	TBT (ms) ↓	Tokens/s ↑	错误率 ↓
vllm-hust v0.17.2rc1.dev450+g289b51ab2.d20260417 @ShuhaoZhangTony • 289b51ab 最新	sharegpt-online	1 x 910B3	1916.7	-	154.6	0.0%
vllm-hust v0.1.dev2743+g7f888566e @ShuhaoZhangTony • 7f888566 基线	sharegpt-online	1 x 910B3	1916.7	442.7	154.6	0.0%

同一 workload 版本对比

这一页不再混放不同 workload，而是收敛到同模型、同硬件、同 workload 的公开提交结果。
当前本地快照中，可直接对比的 sharegpt-online 单机单卡样本共有 2 条。
可点击提交：
289b51ab
7f888566

核心贡献者快照

贡献者

核心贡献者

展示当前持续推动 vLLM-HUST 各仓库运行时、Ascend、benchmark、文档、website 与 workstation 演进的主要贡献者。

快照时间：2026-04-30 • 共 8 位贡献者

排名	贡献者	变更行数	新增 / 删除	活跃仓库数
1	Shuhao Zhang	450,367	312,721 / 137,646	7
2	MinggiWang-coder	21,098	7,282 / 13,816	2
3	Xiling Gao	12,538	12,305 / 233	1
4	KimmoZAG	6,244	4,759 / 1,485	2
5	iliujunn	2,095	1,186 / 909	2
6	CubeLander	802	48 / 754	1
7	pygone	187	164 / 23	1
8	moonandlife	32	17 / 15	2

持续建设这套底座的人

官网持续聚合系列仓库的贡献者快照。
这一页可以直观看到当前哪些人正在推进运行时、Ascend 适配、benchmark、文档、website 与 workstation 的协同演进。

研发队伍与成果落地机制

核心代码与适配队伍

- 持续研究 vllm-hust 核心代码、执行链和平台抽象
- 面向国产硬件做适配策略、插件接入和运行时治理
- 先聚焦华为昇腾，同时保留对其他国产平台的扩展能力

性能优化队伍

- 独立推进吞吐、时延、长上下文与算子路径优化
- 优化成果以平台能力形式沉淀回 vllm-hust
- 目标是将优化成果沉淀为平台能力，并在国产硬件上稳定复用

组织机制

适配工作与性能优化工作通过统一平台持续汇聚，最终沉淀为可复用、可验证、可扩展的国产算力能力体系。

下一阶段重点

1. 继续把硬件差异约束在平台插件、运行时治理和验证配置层，维持主干可持续演进。
2. 围绕多智能体、长上下文、工具调用和多模态交互，补齐近真实业务压力下的系统性验证。
3. 统一 workload schema、指标口径和实验元数据，让不同平台、不同配置下的结果可以稳定比较。
4. 持续同步架构、操作和介绍材料，确保代码演进、验证结论和对外表达保持一致。

阶段目标

从“可以运行”进一步走向“可以交付、可以验证、可以持续优化”的国产推理底座。

谢谢